

INFORME ACADEMICO

Inferencia Bayesiana sobre el Riesgo de Incumplimiento en Consumidores BNPL

Normal-Normal | Regresión Bayesiana MCMC-NUTS | Beta-Binomial | $n=10\ 000$

INTEGRANTES

Levi Parrales

Jose Villegas

Alessandro Paredes

Diego Benitez

Tabla de Contenidos

1. Introduccion

2. Datos y Variable Principal

3. Analisis Descriptivo

3.1 Estadísticas descriptivas de las variables cuantitativas

3.2 Variables categoricas y distribucion del riesgo

3.3 Credit_Score por nivel de riesgo

3.4 Relaciones entre variables - matriz de correlaciones

4. Analisis Bayesiano

4.1 Modelo 1 - Normal-Normal: Credit_Score por grupo de riesgo

4.2 Modelo 2 - Regresion Lineal Bayesiana con MCMC (NUTS)

4.3 Modelo 3 - Beta-Binomial: tasa de pagos tardios por empleo

5. Analisis Etico e Impacto Social

6. Conclusiones

7. Referencias

1. Introduccion

El modelo de financiamiento *Buy Now, Pay Later* (BNPL) ha experimentado un crecimiento acelerado a nivel global. Servicios como Klarna, Afterpay y Affirm permiten a los consumidores fraccionar compras de comercio electronico en cuotas diferidas, a menudo sin intereses explicitos, reduciendo la friccion en el momento de la decision de compra. Sin embargo, este esquema ha generado preocupacion entre reguladores y academicos: al no reportar a las agencias de credito tradicionales y no estar sujetos a las mismas verificaciones de solvencia, los servicios BNPL pueden favorecer la acumulacion silenciosa de deuda, especialmente en consumidores jovenes, estudiantes o con empleo informal (Dobbie & Song, 2015; Gathergood et al., 2019).

El puntaje crediticio (*credit score*) es la medida operativa estandar de solvencia financiera y el indicador mas directamente vinculado al riesgo de incumplimiento. Comprender que factores determinan este puntaje y como varia entre grupos de consumidores BNPL con distintos perfiles demograficos y laborales es fundamental tanto para los proveedores del servicio como para los reguladores.

Pregunta de investigacion

Pregunta: Que factores demograficos, laborales y de comportamiento financiero explican el `Credit_Score` de los usuarios de servicios BNPL, y como difiere este puntaje entre grupos definidos por nivel de riesgo de incumplimiento y estado de empleo?

Objetivo general

Analizar los factores asociados al `Credit_Score` de usuarios de servicios BNPL mediante inferencia bayesiana, cuantificando la incertidumbre posterior sobre las estimaciones y comparando distribuciones entre grupos de riesgo y de estado laboral.

Objetivos especificos

- Estimar bayesianamente la distribucion del `Credit_Score` por grupo de riesgo mediante un modelo Normal-Normal conjugado y calcular la probabilidad posterior de que el grupo de bajo riesgo supere al de alto riesgo.
- Identificar los predictores demograficos, laborales y conductuales del `Credit_Score` mediante regresion lineal bayesiana estimada por MCMC (NUTS), evaluando la significancia mediante intervalos de credibilidad al 95%.
- Comparar la proporcion de pagos tardios entre grupos de estado laboral mediante un modelo Beta-Binomial conjugado, cuantificando la probabilidad posterior de diferencias entre grupos.
- Evaluar las implicaciones eticas del uso de caracteristicas demograficas y laborales como predictores en sistemas de scoring crediticio automatizado.

2. Datos y Variable Principal

2.1 Fuente de datos

Se utilizo el *BNPL Financial Default Risk Dataset* (Kaggle, 2024), un conjunto de datos **sintetico** con **10 000 observaciones** y **11 variables** , disenado para simular el comportamiento crediticio de consumidores de servicios BNPL. La naturaleza sintetica implica que las relaciones estadisticas son plausibles y estructuralmente coherentes, pero no directamente extrapolables a poblaciones reales sin validacion adicional.

2.2 Descripcion de variables

Variable	Tipo	Descripcion
Age	Continua	Edad del consumidor (anos)
Income_USD	Continua	Ingreso anual en USD
Credit_Score ★	Continua	Puntaje crediticio (300-850) - Variable principal
Total_BNPL_Active_Loans	Discreta	Numero de prestamos BNPL activos
Total_BNPL_Debt_USD	Continua	Deuda BNPL total en USD
Average_Transaction_Value_USD	Continua	Valor promedio de transacciones BNPL
Late_Payment_History	Binaria	Historial de pagos tardios (Yes/No)
Employment_Status	Categorica	Employed, Freelancer, Student, Unemployed
Default_Risk	Ordinal	Nivel de riesgo: Low, Medium, High

Tabla 1. Descripcion de las variables. ★ Variable principal.

2.3 Seleccion y justificacion de la variable principal

El **Credit_Score** fue seleccionado como variable principal por cuatro razones: (1) es la medida operativa estandar de solvencia crediticia (rango 300-850); (2) su distribucion es aproximadamente normal (media=663.7, std=76.2, sesgo=-0.66), lo que hace apropiados los modelos probabilisticos normales; (3) su correlacion con **Default_Risk** ($r=-0.41$) confirma su relevancia; (4) a diferencia de **Total_BNPL_Debt_USD** (sesgo=+1.82), no requiere transformaciones que compliquen la interpretacion de los resultados.

2.4 Tratamiento de valores faltantes

Credit_Score e **Income_USD** presentan un 3% de valores faltantes. Bajo el supuesto *MCAR (Missing Completely At Random)*, se adopto el analisis de casos completos: **9 702 observaciones** para los modelos Normal-Normal y Beta-Binomial, y **9 409 observaciones** para la regresion bayesiana. La perdida es menor al 5% y metodologicamente aceptable.

3. Analisis Descriptivo

3.1 Estadísticas descriptivas - variables cuantitativas

La Tabla 2 resume las estadísticas descriptivas. El `Credit_Score` presenta distribución asimétrica a la izquierda ($\text{sesgo} = -0.66$): la mediana (673) es superior a la media (663.7), indicando una cola hacia puntajes bajos. `Income_USD` es aproximadamente simétrico, mientras que `Total_BNPL_Debt_USD` muestra fuerte sesgo positivo ($\text{sesgo} = +1.82$), justificando no usarla como variable principal sin transformación.

Variable	n	Media	Std	Min	Mediana	Max	Sesgo
Age	10 000	34.3	12.9	18	31	64	+0.63
Income_USD	9 695	53 981	29 797	5 000	58 596	139 452	-0.08
Credit_Score	9 702	663.7	76.2	300	673	850	-0.66
BNPL_Active_Loans	10 000	2.32	1.85	0	2	10	+1.38
BNPL_Debt_USD	10 000	348.8	315.1	0	262.5	2 731	+1.82
Avg_Transact_USD	10 000	331.8	264.4	10	294.5	1 420	+0.79

Tabla 2. Estadísticas descriptivas. ★ Variable principal.




Figura 1. Distribuciones de las variables cuantitativas (histograma + KDE). Se aprecia la asimetría negativa del `Credit_Score` y la fuerte asimetría positiva de la deuda BNPL, que justifica la selección del `Credit_Score`.

3.2 Variables categoricas y distribucion del riesgo

La variable **Default_Risk** muestra un marcado desbalance de clases típico de datos crediticios: el **88.0%** pertenece al nivel bajo (*Low*), el 6.8% al nivel medio y el 5.2% al nivel alto. Este desbalance refleja que la gran mayoría de los usuarios no presenta signos de incumplimiento, pero el subgrupo de alto riesgo es el de mayor interés analítico. En cuanto a **Employment_Status**, predominan los empleados formales (60.3%), seguidos de estudiantes (19.7%), independientes (14.9%) y desempleados (5.1%).

Distribución de Variables Categóricas




Figura 2. Distribución de las variables categóricas principales. El desbalance en Default_Risk es característico de datos crediticios reales.

3.3 Credit_Score por nivel de riesgo

La diferencia entre el grupo de bajo riesgo (media=675.3) y el de alto riesgo (media=566.2) asciende a **109 puntos**, brecha estadísticamente y prácticamente significativa. En términos del scoring crediticio, esta diferencia equivale a la transición entre categorías de crédito con impacto directo sobre tasas de interés y probabilidad de aprobación. Este hallazgo anticipa los resultados del análisis bayesiano.

Grupo	n	Media	Std	Min	Max
Low (bajo riesgo)	8 539	675.3	67.4	337	850
Medium (riesgo medio)	654	587.3	83.2	320	844
High (alto riesgo)	509	566.2	79.7	300	770

Tabla 3. Estadísticas del Credit_Score por grupo de Default_Risk.

Credit_Score según Nivel de Riesgo de Incumplimiento




Figura 3. Distribución del Credit_Score por grupo (violin + boxplot). La separación entre grupos es clara. La brecha Low-High es de 109 pts.

3.4 Relaciones entre variables - matriz de correlaciones

La matriz de correlaciones revela dos relaciones clave: **Credit_Score con Income_USD** ($r=0.51$), asociación positiva moderada; y **Credit_Score con Default_Risk** codificado numericamente ($r=-0.41$). Notablemente, las variables de comportamiento BNPL presentan correlaciones casi nulas con el Credit_Score (préstamos activos: $r=0.015$; deuda: $r=0.008$), sugiriendo que el uso del servicio BNPL per se no predice el puntaje. Este hallazgo anticipa el resultado de la regresión bayesiana.




Figura 4. Matriz de correlaciones de Pearson. Correlaciones clave: Credit_Score-Income ($r=0.51$), Credit_Score-Default_Risk ($r=-0.41$). Las variables BNPL tienen correlaciones casi nulas con el Credit_Score.

4. Analisis Bayesiano

El analisis bayesiano se estructura en tres modelos complementarios que forman una **cadena argumental integrada**: el primer modelo cuantifica la diferencia en Credit_Score entre grupos de riesgo; el segundo identifica que variables predicen ese puntaje; el tercero explica por que ciertos grupos tienen peores historiales de pago. Juntos construyen una explicacion coherente del riesgo BNPL desde sus determinantes hasta sus manifestaciones.

4.1 Modelo 1 - Normal-Normal: Credit_Score por grupo de riesgo

Objetivo

Estimar la distribucion posterior de la media del Credit_Score (μ_k) para cada grupo de Default_Risk y calcular la probabilidad bayesiana de que el grupo de bajo riesgo supere al de alto riesgo en puntaje promedio.

Especificacion y metodo de estimacion

Componente	Distribucion	Justificacion
Verosimilitud	$Y_i \mu_k \sim \text{Normal}(\mu_k, \sigma_k^2)$	Credit_Score es continuo y aprox. normal dentro de cada grupo
Prior	$\mu_k \sim \text{Normal}(\mu_0=650, \tau_0=100)$	$\mu_0=650$ pts: media razonable para BNPL. IC 95%=[454,846]: debilmente informativo
Posterior (analitico)	$\mu_k \text{datos} \sim \text{Normal}(\mu_n, \tau_n^2)$	$\tau_n^2 = (1/\tau_0^2 + n/\sigma_k^2)^{-1}$; $\mu_n = \tau_n^2 * (\mu_0/\tau_0^2 + \bar{y}_k * n/\sigma_k^2)$

Tabla 4. Especificacion del modelo Normal-Normal. La conjugacion permite solucion analitica exacta sin simulacion.

El modelo Normal-Normal es conjugado: la distribucion posterior se obtiene **analiticamente** aplicando las formulas de actualizacion bayesiana. Con muestras grandes ($n > 500$), el prior debilmente informativo tiene influencia minima y la posterior coincide practicamente con la media muestral. La distribucion posterior de la diferencia ($\mu_{\text{Low}} - \mu_{\text{High}}$) se obtiene directamente: la diferencia de dos normales es normal, con media y varianza calculadas de forma exacta.

Resultados

Grupo	n	ybar obs.	mun posterior	taun	IC 95% inf.	IC 95% sup.
Low	8 539	675.33	675.33	0.73	673.90	676.76
Medium	654	587.32	587.39	3.25	581.02	593.76
High	509	566.23	566.33	3.53	559.42	573.25

Tabla 5. Distribuciones posteriores de μ_k . Los IC al 95% son muy estrechos (+1.5 pts para Low, +7 pts para High), indicando alta precisión en la estimación.

Distribuciones a priori y posteriores del Credit Score por grupo de riesgo




Figura 5. Distribuciones posteriores de μ_k por grupo. Las distribuciones no se solapan entre sí, anticipando la certeza bayesiana del resultado.

Resultado principal - Modelo Normal-Normal

$E[\mu_{\text{Low}} - \mu_{\text{High}} | \text{datos}] = \mathbf{108.99 \text{ puntos}}$ | IC 95%: [101.95, 116.03]

$P(\mu_{\text{High}} < \mu_{\text{Low}} | \text{datos}) = \mathbf{1.000000}$ | $P(\mu_{\text{Med}} < \mu_{\text{Low}}) = \mathbf{1.000000}$

La brecha de 109 puntos entre los grupos extremos se estima con certeza bayesiana total: el límite inferior del IC al 95% (102 pts) está muy alejado del cero. En el contexto del scoring crediticio, esta diferencia equivale a la transición entre categorías de crédito (p.ej., de "Fair" a "Good" o "Good" a "Very Good" en escala FICO), con consecuencias directas sobre tasas de interés y aprobación.

Comparación bayesiana del Credit Score entre grupos de riesgo




Figura 6. Distribucion posterior de la diferencia $\mu_{Low} - \mu_{High}$. Toda la masa de probabilidad esta en valores positivos, confirmando con certeza bayesiana que el grupo de bajo riesgo tiene mayor Credit_Score.

4.2 Modelo 2 - Regresion Lineal Bayesiana con MCMC (NUTS)

Objetivo

Identificar que variables demograficas, laborales y conductuales predicen el Credit_Score, y cuantificar la magnitud e incertidumbre de cada efecto mediante distribuciones posteriores con IC al 95%.

Especificacion del modelo

Se especifico un modelo de regresion lineal bayesiana con 9 predictores: 4 variables continuas estandarizadas (z-score), 1 variable binaria y 3 dummies de estado laboral (referencia: Employed):

Componente	Distribucion	Justificacion
Verosimilitud	$Credit_Score_i \sim Normal(\mu_i, \sigma^2)$	Normal apropiada para variable continua en rango [300,850]
Funcion de enlace	$\mu_i = \beta_0 + \sum(\beta_{aj} * X_{ij}) + \gamma_k * Empleo$	9 predictores; continuas estandarizadas para comparabilidad de coeficientes
Prior intercepto	$\beta_0 \sim Normal(650, 100^2)$	650 pts media generica BNPL; IC 95%=[454,846] debilmente informativo
Prior coeficientes	$\beta_{aj} \sim Normal(0, 50^2)$	Centrado en cero (sin efecto a priori); IC 95%=[-98,+98] pts
Prior dispersion	$\sigma \sim HalfNormal(80)$	Prior difuso; admite solo valores positivos por definicion

Tabla 6. Especificacion del modelo de regresion lineal bayesiana.

Metodo de estimacion - MCMC con NUTS

Dado que este modelo no admite solucion analitica, se estimo mediante **Cadenas de Markov Monte Carlo (MCMC)** usando el algoritmo **No-U-Turn Sampler (NUTS)** en **PyMC v5**. NUTS es una variante adaptativa del muestreo de Hamilton (HMC) que ajusta automaticamente la longitud del trayecto en el espacio de parametros, eliminando la necesidad de sintonizacion manual y reduciendo drasticamente la autocorrelacion entre muestras. A diferencia de Metropolis-Hastings, HMC utiliza informacion del gradiente de la log-posterior para proponer saltos mas eficientes.

La configuracion fue: **4 cadenas independientes**, **1 000 iteraciones de ajuste** (*tuning/warm-up*) descartadas, **1 000 iteraciones de muestreo** por cadena (4 000 muestras totales), *target_accept*=0.92 y *random_seed*=42.

Diagnostico de convergencia

La convergencia se evaluo con tres criterios estandar (Vehtari et al., 2021; Gelman et al., 2013; Hoffman & Gelman, 2014):

- **R² de Gelman-Rubin**: mide varianza entre cadenas relativa a varianza dentro de las cadenas. R²=1.0 indica convergencia perfecta; criterio: R² < 1.01. Valor maximo obtenido: **1.0013** - criterio alcanzado.
- **ESS (Effective Sample Size)**: numero efectivo de muestras independientes, corrigiendo por autocorrelacion. Criterio minimo: ESS > 400. ESS bulk minimo obtenido: **2 675** - muy superior al umbral.

• **Divergencias NUTS:** indicadores de problemas geometricos en el espacio posterior. Se obtuvieron **0 divergencias**, confirmando exploracion sin dificultades numericas.

Criterio	Valor obtenido	Umbral	Estado
R ² max. (Gelman-Rubin)	1.0013	< 1.01	✓ Convergencia
ESS bulk minimo	2 675	> 400	✓ Suficiente
Divergencias NUTS	0	= 0	✓ Sin problemas
Cadenas / Draw / Tune	4 / 1000 / 1000	-	4 000 muestras totales

Tabla 7. Diagnostico de convergencia MCMC. Todos los criterios son satisfactorios.




Figura 7. Trazas MCMC (izq.) y distribuciones marginales posteriores (der.) para cuatro parametros representativos. Las trazas estacionarias y bien mezcladas confirman visualmente la convergencia de las cadenas.

Coeficientes bayesianos e interpretaciones

Las variables continuas estan estandarizadas (z-score): el coeficiente β_j representa el cambio esperado en Credit_Score por 1 desviacion estandar en X_j , manteniendo el resto constante. Los coeficientes de empleo representan la diferencia respecto a los empleados formales (referencia). ✓ indica IC al 95% separado del cero (efecto significativo).

Parametro	Media post.	Std	IC 95% inf.	IC 95% sup.	R ²	Sig.
Intercepto (β_0)	705.65	0.91	703.87	707.46	1.001	-
Ingreso anual (std)	+1.32	0.92	-0.51	+3.16	1.000	-
Edad (std)	+0.18	0.56	-0.91	+1.27	1.000	-
Prestamos BNPL activos (std)	+0.80	0.56	-0.31	+1.92	1.000	-
Val. prom. transaccion (std)	-0.30	0.57	-1.41	+0.81	1.001	-
Pago tardio ($S_i=1$)	-43.41	1.36	-46.18	-40.80	1.000	✓
Empleo: Student	-88.62	2.32	-93.07	-84.06	1.001	✓
Empleo: Freelancer	-47.15	1.70	-50.50	-43.80	1.000	✓
Empleo: Unemployed	-133.92	3.28	-140.42	-127.35	1.001	✓
sigma residual	55.04	0.41	54.23	55.84	1.000	-

Tabla 8. Resumen posterior de los coeficientes. Referencia: Employed, sin pago tardio. Variables continuas estandarizadas (z-score). ✓ = IC 95% no incluye el cero.

Hallazgo central: las cuatro variables continuas (ingreso, edad, prestamos, valor de transacciones) tienen IC al 95% que incluyen el cero: condicionalmente al tipo de empleo, no hay evidencia bayesiana de efecto directo sobre el Credit_Score. El efecto del ingreso parece estar mediado por el tipo de empleo: al controlar el estado laboral, el ingreso adicional no aporta informacion incremental significativa.

En contraste, las variables categoricas muestran efectos masivos:

- **Desempleo (Unemployed):** reduce el Credit_Score en **133.9 puntos** (IC 95%: [-140.4, -127.4]). El efecto mas grande del modelo. Un consumidor desempleado con identico perfil financiero que uno empleado tendra 134 puntos menos, lo que puede excluirlo del acceso a credito formal.
- **Ser estudiante (Student):** reduce el Credit_Score en **88.6 puntos** (IC 95%: [-93.1, -84.1]). Refleja historiales crediticios mas cortos y mayores limitaciones de ingreso de este grupo demografico.
- **Trabajo independiente (Freelancer):** reduce el Credit_Score en **47.2 puntos** (IC 95%: [-50.5, -43.8]). Efecto intermedio, consistente con mayor variabilidad de ingresos del trabajo autonomo.
- **Historial de pagos tardios:** reduce el Credit_Score en **43.4 puntos** (IC 95%: [-46.2, -40.8]). Efecto directo e independiente del tipo de empleo: tener pagos tardios reduce el puntaje en ~43 puntos adicionales sin importar la situacion laboral.




Figura 8. Forest plot bayesiano: media posterior, IQR (50%) e IC 95%. Rojo: IC 95% separado del cero (efectos significativos). Las variables continuas no son significativas al controlar por tipo de empleo.

Verificación predictiva posterior (PPC)

La PPC evalúa si el modelo genera datos simulados coherentes con los observados. La Figura 9 muestra que la distribución de replicas (y_{rep}) reproduce fielmente la distribución observada (y_{obs}) en forma y rango, confirmando que el modelo captura adecuadamente la estructura de los datos y que sus predicciones son confiables.




Figura 9. Verificación predictiva posterior. Las replicas simuladas (azul) reproducen bien la distribución observada del Credit_Score (negro).

Predicciones para perfiles representativos

La Tabla 9 muestra predicciones del Credit_Score para tres perfiles hipotéticos. La diferencia entre el perfil más y menos favorable asciende a **179 puntos**, con consecuencias directas sobre el acceso al crédito formal.

Perfil	Características	Credit_Score pred.	IC 95%
Empleado estandar	Income=\$75k, Edad=35, sin pago tardio	706	[599, 814]
Estudiante tipico	Income=\$12k, Edad=22, sin pago tardio	615	[508, 724]
Desempleado pagos tardios c/	Income=\$15k, Edad=27, con pago tardio	527	[420, 638]

Tabla 9. Predicciones bayesianas para perfiles representativos. IC al 95% incluye la incertidumbre del modelo (sigma aprox. 55 pts).

4.3 Modelo 3 - Beta-Binomial: tasa de pagos tardios por estado laboral

Objetivo

Estimar la distribucion posterior de la proporcion de pagos tardios (π_k) para cada grupo de Employment_Status y calcular la probabilidad bayesiana de que ciertos grupos tengan tasas significativamente superiores. Este modelo cierra la cadena causal: si el desempleo reduce el Credit_Score (Modelo 2), el Modelo 3 explica el mecanismo - los desempleados tienen historiales de pago mucho mas deteriorados.

Especificacion y metodo

Componente	Distribucion	Justificacion
Verosimilitud	$X_k \pi_k \sim \text{Binomial}(n_k, \pi_k)$	X_k = pagos tardios en el grupo k; n_k = tamaño del grupo
Prior	$\pi_k \sim \text{Beta}(1, 1) = \text{Uniforme}(0,1)$	Prior no informativo: todos los valores de la tasa son igualmente plausibles
Posterior (analitico)	$\pi_k \text{datos} \sim \text{Beta}(1+X_k, 1+n_k-X_k)$	Solucion conjugada exacta; la Beta es el prior conjugado de la Binomial

Tabla 10. Especificacion del modelo Beta-Binomial. La conjugacion permite solucion analitica exacta.

El modelo Beta-Binomial admite solucion analitica exacta: la posterior de cada grupo es $\text{Beta}(1+X_k, 1+n_k-X_k)$. Las probabilidades de superioridad entre grupos se calculan mediante **simulacion Monte Carlo**: se generan 100 000 muestras de cada posterior Beta y se estima la proporcion de casos en que la muestra del grupo de mayor riesgo supera a la del menor. Este Monte Carlo actua como verificacion numerica de una comparacion ya evidente dado el escaso solapamiento de las distribuciones posteriores.

Resultados

Grupo	n	Pag. tard.	π obs.	π post. (media)	IC 95% inf.	IC 95% sup.
Employed	6 029	902	15.0%	14.97%	14.1%	15.9%
Freelancer	1 495	395	26.4%	26.45%	24.3%	28.7%
Student	1 968	869	44.2%	44.16%	42.0%	46.4%
Unemployed	508	310	61.0%	60.98%	56.7%	65.2%

Tabla 11. Distribuciones posteriores de π_k . Con prior uniforme $\text{Beta}(1,1)$, la media posterior coincide practicamente con la proporcion observada.

Los resultados revelan diferencias marcadas y bien separadas. Los **desempleados** presentan una tasa de pagos tardios del **61%**, cuatro veces superior a la de los empleados formales (15%). Estudiantes (44%) e independientes (27%) ocupan posiciones intermedias, reflejando la mayor precariedad de sus situaciones laborales. Las distribuciones posteriores son muy estrechas para los Employed ($n=6\ 029$), indicando alta precision; para los Unemployed ($n=508$) son algo mas amplias pero siguen sin solaparse con las de los Employed.

Distribuciones posteriores de la tasa de pagos tardíos por estado laboral




Figura 10. Distribuciones posteriores $\text{Beta}(1+X_k, 1+n_k-X_k)$. Las distribuciones de *Employed* y *Unemployed* no se solapan en absoluto, confirmando con certeza bayesiana la diferencia entre grupos.

Distribuciones posteriores de la diferencia ($\pi_k - \pi_{\text{Employed}}$)




Figura 11. Distribuciones posteriores de las diferencias $\pi_k - \pi_{\text{Employed}}$. Toda la masa de probabilidad esta en valores positivos para los tres grupos.

Resultado principal - Modelo Beta-Binomial

$P(\pi_{\text{Unemployed}} > \pi_{\text{Employed}} \mid \text{datos}) = \mathbf{1.0000}$ | Diferencia: +0.460, IC 95%: $[0.417, 0.503]$

$P(\pi_{\text{Student}} > \pi_{\text{Employed}} \mid \text{datos}) = \mathbf{1.0000}$ | Diferencia: +0.292, IC 95%: $[0.268, 0.316]$

$P(\pi_{\text{Freelancer}} > \pi_{\text{Employed}} \mid \text{datos}) = \mathbf{1.0000}$ | Diferencia: +0.115, IC 95%: $[0.093, 0.137]$

Los tres grupos no-Employed tienen tasas de pagos tardíos significativamente superiores con certeza bayesiana total. Este resultado cierra la cadena causal: el estado laboral determina la frecuencia de pagos tardíos, que deteriora el historial crediticio, reduce el *Credit_Score* y eleva el riesgo de incumplimiento.

5. Analisis Etico e Impacto Social

El uso de modelos estadísticos en decisiones crediticias plantea dilemas éticos que van más allá de la validez técnica. Los modelos desarrollados identifican variables de alta capacidad predictiva - especialmente el estado laboral - pero su aplicación en sistemas de decisión automatizada conlleva riesgos que merecen examen explícito.

Discriminación estadística y equidad algorítmica

El modelo asigna un Credit_Score predicho 134 puntos inferior a los desempleados y 89 puntos inferior a los estudiantes respecto a los empleados formales. Desde la perspectiva estadística, este resultado es válido. Desde la perspectiva de la equidad, implica que consumidores son penalizados por características temporales (el desempleo o el ser estudiante son fases de vida) o que reflejan desigualdades estructurales previas (barreras de acceso al empleo formal).

Analisis de escenarios

- **Corto plazo:** Si este modelo se usa para decisiones automáticas de aprobación BNPL, los desempleados y estudiantes enfrentarán condiciones más restrictivas, agravando la exclusión financiera del segmento que más podría beneficiarse del acceso razonable al crédito.
- **Mediano plazo:** Normalizar modelos de scoring en BNPL puede aumentar la eficiencia del mercado (reduciendo morosidad), pero a costa de reducir la inclusión financiera. Este equilibrio es una decisión regulatoria.
- **Largo plazo:** Si los modelos se entrenan con datos que reflejan discriminación histórica, la reproduzcan de forma auto-perpetuante, creando ciclos de exclusión difíciles de romper sin intervención deliberada.

Dilema ético central

Tiene una institución el derecho de utilizar el tipo de empleo como factor determinante en un modelo de riesgo crediticio automatizado?

Desde la eficiencia del mercado: sí. Estas variables tienen poder predictivo estadísticamente respaldado y reducen la morosidad. Desde la equidad: es cuestionable. Las personas no deberían ser excluidas de servicios financieros por características temporales o que reflejan desigualdades estructurales. Los reguladores y equipos de ética en IA deben determinar qué variables son admisibles en sistemas de decisión automatizada.

6. Conclusiones

Cadena causal integrada - validada por los tres modelos

Estado laboral -> comportamiento de pago -> historial crediticio -> Credit_Score -> riesgo de incumplimiento BNPL.

- **Conclusion 1 - Diferencia entre grupos confirmada:** Los consumidores de alto riesgo tienen Credit_Score promedio 109 puntos inferior al de los de bajo riesgo (IC 95%: [102, 116], $P_{\text{posterior}}=1.000000$). Esta brecha equivale a la transición entre categorías crediticias con impacto directo sobre tasas de interés y acceso al crédito.
- **Conclusion 2 - El estado laboral domina la predicción:** El modelo MCMC-NUTS ($R\text{-hat}_{\text{max}}=1.0013$, ESS $\text{min}=2\ 675$, 0 divergencias) demuestra que ser desempleado reduce el Credit_Score en 134 puntos y tener historial de pagos tardíos lo reduce en 43 puntos adicionales, ambos con IC al 95% separados del cero. Las variables continuas no son significativas al controlar por empleo.
- **Conclusion 3 - El desempleo cuadruplica el riesgo de pago tardío:** El modelo Beta-Binomial (conjugado analítico) confirma con $P=1.0000$ que los desempleados tienen tasa de pagos tardíos (61%) cuatro veces mayor que los empleados (15%). Esto explica mecánicamente el efecto dominante del Modelo 2.
- **Conclusion 4 - Limitaciones:** Dataset sintético sin contexto geográfico limita la generalización. Se recomienda validación sobre datos observacionales reales. La posible circularidad entre Credit_Score y Default_Risk en el dataset podría inflar las correlaciones observadas.
- **Lineas de investigacion futura:** Modelos jerárquicos bayesianos con variación geográfica; clasificación bayesiana directa sobre Default_Risk; análisis de equidad (fairness) con métricas de igualdad de oportunidades; comparación con modelos frecuentistas equivalentes.

7. Referencias

1. Dobbie, W., & Song, J. (2015). Debt relief and debtor outcomes. *American Economic Review*, 105(3), 1272-1311. <https://doi.org/10.1257/aer.20130612>
2. Gathergood, J., Mahoney, N., Stewart, N., & Weber, J. (2019). How do individuals repay their debt? *American Economic Review*, 109(3), 844-875.
3. Gelman, A., Carlin, J. B., Stern, H. S., Dunson, D. B., Vehtari, A., & Rubin, D. B. (2013). *Bayesian Data Analysis* (3a ed.). Chapman and Hall/CRC.
4. Hoffman, M. D., & Gelman, A. (2014). The No-U-Turn Sampler. *JMLR*, 15(1), 1593-1623.
5. PyMC Development Team. (2023). *PyMC: Probabilistic programming in Python* (v5). <https://www.pymc.io>
6. Salvatier, J., Wiecki, T. V., & Fonnesbeck, C. (2016). Probabilistic programming in Python using PyMC3. *PeerJ Computer Science*, 2, e55.
7. Vehtari, A., Gelman, A., Simpson, D., Carpenter, B., & Burkner, P.-C. (2021). Rank-normalization, folding, and localization: An improved R-hat. *Bayesian Analysis*, 16(2), 667-718.