

# Inferencia Bayesiana sobre el Riesgo de Incumplimiento en Consumidores BNPL

ESPOL | Estadística Bayesiana | Término 1 - 2026

Modelo Normal-Normal | Regresión Bayesiana MCMC-NUTS | Modelo Beta-Binomial | n = 10 000

Levi Parrales | Jose Villegas | Alessandro Paredes | Diego Benítez

## CONTEXTO Y PREGUNTA DE INVESTIGACION

El sector BNPL (Buy Now, Pay Later) ha crecido exponencialmente. Servicios como Klarna, Afterpay y Affirm permiten compras a plazo sin reportar a agencias crediticias tradicionales, generando riesgo de acumulación silenciosa de deuda.

### Pregunta de investigación:

Que factores demográficos, laborales y conductuales predicen el **Credit\_Score** de los usuarios BNPL? ¿se mantendrá entre amigos de riesgo? ¿se mantendrá?

## DATOS Y VARIABLE PRINCIPAL

10 000

Consumidores

11

Variables

663.7

Media Credit Score

88.0%

Bajo Riesgo

### Variable principal: Credit\_Score

&#8226; Rango: 300-850 | Media: 663.7 | Std: 76.2  
&#8226; Distribución aprox. normal (sesgo = -0.66)  
&#8226; Correlación con Default\_Risk: r = -0.41

## CADENA CAUSAL INTEGRADA

Estado laboral

>

Pagos tardíos

>


Credit\_Score

Modelo 1: Credit Score por grupo de riesgo  
Modelo 2: Regresión MCMC-NUTS (predictores)  
Modelo 3: Tasa de pagos tardíos por empleo

## MODELO 1 — NORMAL-NORMAL (Conjugado)

Verosimilitud:  $Y_i | \mu, \sigma^2 \sim \text{Normal}(\mu, \sigma^2)$   
Prior:  $\mu \sim \text{Normal}(650, 100^2)$  — debilmente informativo  
Posterior:  $\mu, \sigma^2 | \text{datos} \sim \text{Normal}(\mu_n, \tau_n \sigma^2)$   
Metodo: Solución analítica exacta (conjugado)

| Grupo              | $\mu_n$ posterior | IC 95%         |
|--------------------|-------------------|----------------|
| Low (bajo riesgo)  | 675.3 pts         | [673.9, 676.8] |
| Medium             | 587.4 pts         | [581.0, 593.8] |
| High (alto riesgo) | 566.3 pts         | [559.4, 573.3] |



Distribuciones posteriores de  $\mu_k$  por grupo


$E[\mu_{\text{Low}} - \mu_{\text{High}} | \text{datos}] = 108.99 \text{ pts}$

IC 95% [101.95, 116.03]

$P(\mu_{\text{High}} < \mu_{\text{Low}} | \text{datos}) = 1.000000$

Certeza bayesiana total: el grupo de bajo


riesgo es el más seguro con  $P = 1.000000$



Posterior diferencia  $\mu_{\text{Low}} - \mu_{\text{High}}$

## MODELO 2 — REGRESIÓN BAYESIANA MCMC-NUTS

Algoritmo: No-U-Turn Sampler (NUTS) via PyMC v5  
Config.: 4 cadenas  $\times$  1 000 draw + 1 000 tune = 4 000 muestras  
R-hat max: 1.0013 | ESS bulk min: 2 675 | Divergencias: 0  
Todos los criterios de convergencia satisfichos



Forest plot bayesiano — coeficientes con IC 95%

| Predictor                | Beta   | IC 95%           | Sig.     |
|--------------------------|--------|------------------|----------|
| Ingreso anual (std)      | +1.32  | [-0.5, +3.2]     | -        |
| Edad (std)               | +0.18  | [-0.9, +1.3]     | -        |
| Pagos tardíos (Si=1)     | -43.4  | [-46.2, -40.8]   | &#10003; |
| Student (vs Employed)    | -88.6  | [-93.1, -84.1]   | &#10003; |
| Freelancer (vs Employed) | -47.2  | [-50.5, -43.8]   | &#10003; |
| Unemployed               | -133.9 | [-140.4, -127.4] | &#10003; |

Unemployed: -133.9 pts (IC: [-140.4, -127.4])


Student: -88.6 pts (IC: [-93.1, -84.1])

Freelancer: -47.2 pts (IC: [-50.5, -43.8])

Pago tardío: -43.4 pts (IC: [-46.2, -40.8])

Variables continuas:

IC al 95% incluye €




Verificación predictiva posterior (PPC)

## MODELO 3 — BETA-BINOMIAL (Conjugado)

Verosimilitud:  $X_k | p_k \sim \text{Binomial}(n_k, p_k)$   
Prior:  $p_k \sim \text{Beta}(1, 1)$  — no informativo (uniforme)  
Posterior:  $p_k | \text{datos} \sim \text{Beta}(1+x_k, 1+n_k-x_k)$   
Metodo: Solución analítica exacta (conjugado)

| Grupo      | $p_i$ posterior | IC 95%         |
|------------|-----------------|----------------|
| Employed   | 15.0%           | [14.1%, 15.9%] |
| Freelancer | 26.5%           | [24.3%, 28.7%] |
| Student    | 44.2%           | [42.0%, 46.4%] |
| Unemployed | 61.0%           | [56.7%, 65.2%] |



Distribuciones posteriores Beta por grupo

$P(p_{\text{Unemployed}} > p_{\text{Employed}}) = 1.0000$

Diferencia: +0.460, IC 95%: [0.417, 0.503]

$P(p_{\text{Student}} > p_{\text{Employed}}) \approx 1.0000$

## CONCLUSIONES PRINCIPALES

- Diferencia Low-High: 109 pts ( $P = 1.000000$ ). IC 95%: [101.95, 116.03]
- Unemployed: -133.9 pts en Credit\_Score. Freelancer: -47.2 | Student: -88.6 pts
- Pago tardío: -43.4 pts adicionales.
- Desempleados: tasa pago tardío 4x mayor. 61% vs 15% en empleados ( $P = 1.0000$ )
- Ingreso y edad NO significativos al controlar por tipo de empleo.
- Cadena causal validada con certeza bayesiana en los 3 modelos.

## CONSIDERACIONES ETICAS

Usar tipo de empleo en scoring puede excluir poblaciones laboralmente vulnerables. Los sistemas deben incorporar métricas de equidad (fairness) junto a la precisión predictiva.